

Actividad 5.2 — Regresión Lineal Simple

Reporte de hallazgos · Bases de datos del socio formador GAC

Este reporte documenta el preprocesamiento (nulos y valores atípicos), el análisis de correlación y los modelos de regresión lineal simple obtenidos para dos bases de datos de GAC: **Análisis de Piso y Ventas por Asesor**. El código completo, ejecutado en Google Colab, se encuentra en los notebooks que acompañan este documento en el repositorio.

1. Base de datos: Análisis de Piso

1.1 Preprocesamiento

La base contiene 40 asesores y 51 columnas numéricas (leads mensuales, ventas mensuales, rankings y factores de conversión). La columna **Raking_Ventas** incluía el texto "-" en 11 filas; se convirtió a tipo numérico con `pd.to_numeric(..., errors='coerce')`, dejando esas filas como nulas. Los valores atípicos se identificaron con el método de **desviación estándar** (fuera de $\pm 3\sigma$) y se imputaron con la media de cada columna; no quedaron valores nulos después de la limpieza.

1.2 Matriz de correlación

Se calculó la correlación de Pearson entre las 51 variables numéricas. El mapa de calor muestra bloques de alta correlación entre meses consecutivos de leads y de ventas (comportamiento estacional esperado), y una correlación negativa fuerte entre los rankings y sus variables base (a mayor ranking numérico, menor volumen, por construcción del ranking).




Figura 1. Matriz de correlación — Análisis de Piso.

1.3 Pares más correlacionados

Variable 1	Variable 2	Correlación
Ventas_2024_jun	Ventas_2024_oct	1.000
Leads_2025_ene	Ventas_2024_dic	0.944
Factor_SDC	Raking_SDC	0.928
Ventas_2025_mar	Ventas_2025_abr	0.909
Factor_PDM	Raking_PDM	0.890
Total_Leads_Ajustado	T_Ventas_Piso	0.860
Total_Leads	Raking_Leads	-0.854

1.4 Regresión lineal simple: Leads Ajustado → Ventas Históricas

Se probó primero **Total_Leads** (sin ajustar) como predictor de **Total_Ventas_Historicas**, pero la relación resultó prácticamente nula ($R^2 = 0.027$). En cambio, **Total_Leads_Ajustado** — que pondera

los leads recibidos por algún factor de calidad o tiempo en piso — sí muestra una relación lineal moderada:




Figura 2. Regresión lineal — Leads Ajustado vs Ventas Históricas.

Ecuación: $Ventas = 0.2016 \times Leads_Ajustado + 2.9612 \quad | \quad R^2 = 0.311$

Hallazgo: el volumen de leads ajustado explica alrededor del 31% de la variación en las ventas históricas de un asesor — una relación positiva y moderada, no despreciable, pero que deja claro que la mayoría de la variación en ventas (69%) depende de otros factores (habilidad de cierre, seguimiento, tipo de cliente, etc.) y no solo del volumen de leads recibido. Esto también explica por qué el conteo bruto de leads (sin ajustar) no predice ventas: no todos los leads tienen la misma calidad o probabilidad de conversión.

2. Base de datos: Ventas por Asesor

2.1 Preprocesamiento

La base contiene 51 vendedores y 38 columnas numéricas (ventas mensuales de febrero 2024 a julio 2026, acumulados y rankings anuales). No se encontraron valores nulos ni columnas con texto no numérico. Los valores atípicos se trataron igualmente con el método de desviación estándar ($\pm 3\sigma$), imputando con la media.

2.2 Matriz de correlación

El mapa de calor muestra correlación alta entre meses consecutivos o cercanos (rachas de ventas), y correlación negativa fuerte entre los rankings anuales y sus respectivos acumulados (a mayor ranking numérico, menor acumulado, por definición del ranking).




Figura 3. Matriz de correlación — Ventas por Asesor.

2.3 Pares más correlacionados

Variable 1	Variable 2	Correlación
------------	------------	-------------

Acum_2026	Ranking_2026	-0.922
Ventas_2025-10	Acum_2025	0.898
Ventas_2026-01	Col_811	0.887
Ventas_2026-03	Acum_2026	0.877
Ventas_2025-05	Acum_2025	0.873
Acum_2024	Ranking_2024	-0.820

2.4 Regresión lineal simple: Acumulado 2025 → Acumulado 2026

Se eligió este par porque es el más correlacionado entre dos variables de negocio directamente comparables (ventas acumuladas de un año vs. el siguiente), lo que permite estimar el desempeño de un vendedor en 2026 a partir de su desempeño en 2025:




Figura 4. Regresión lineal — Acum 2025 vs Acum 2026.

Ecuación: $Acum_2026 = 0.3150 \times Acum_2025 + 1.4809 \mid R^2 = 0.352$

Hallazgo: el desempeño de 2025 explica cerca del 35% de la variación en el desempeño de 2026, la relación más fuerte entre variables no derivadas directamente una de la otra en esta base. Es una relación positiva moderada: los vendedores con buen acumulado en 2025 tienden a mantener mejores resultados en 2026, aunque el 65% restante de la variación (visible en el grupo grande de vendedores en 0 para ambos años, y en los que caen a pesar de un buen 2025) confirma el hallazgo de rotación descrito en el reporte de valores atípicos: el desempeño histórico no garantiza continuidad.

3. Conclusión general

En ambas bases, las regresiones lineales simples muestran relaciones positivas pero moderadas (R^2 entre 0.31 y 0.35): los leads y el desempeño pasado ayudan a explicar una parte real de las ventas, pero no son suficientes por sí solos para predecirlas con precisión. Esto sugiere que un modelo de regresión múltiple, que combine varias variables (leads ajustados, conversión, historial), probablemente explicaría una porción mayor de la variación observada en ambas bases.